

# NGBoost: Natural Gradient Boosting for Probabilistic Prediction

---

Kobe University  
201T264T  
Fuki Yamamoto

# 発表の流れ

---

1. 論文の背景, 概要

2. 準備

3. 手法の説明

4. 実験結果

5. まとめ

# 論文の概要

---

タイトル

NGBoost: Natural Gradient Boosting for Probabilistic Prediction

著者

Duan, Tony, et al.

出典

International Conference on Machine Learning. PMLR, 2020.

- 回帰問題において, 予測の不確かさを扱うことができる  
Gradient Boosting Decision Tree (GBDT)モデルを提案
- 勾配にnatural gradient(自然勾配)(Amari, 1998)を用いている

# 背景 (予測の不確かさとは)


回帰問題において、予測値だけでなく、  
確率分布そのものを出力できれば活用の幅が広がる

→  $x$  °C以上になる確率は?,  $x$ ヶ月以内に亡くなる確率は?

予測の信頼度はどの程度? (分類問題では普通)


What will be the  
temperature at noon  
tomorrow?

73.4 Fahrenheit



How long will this patient  
live?

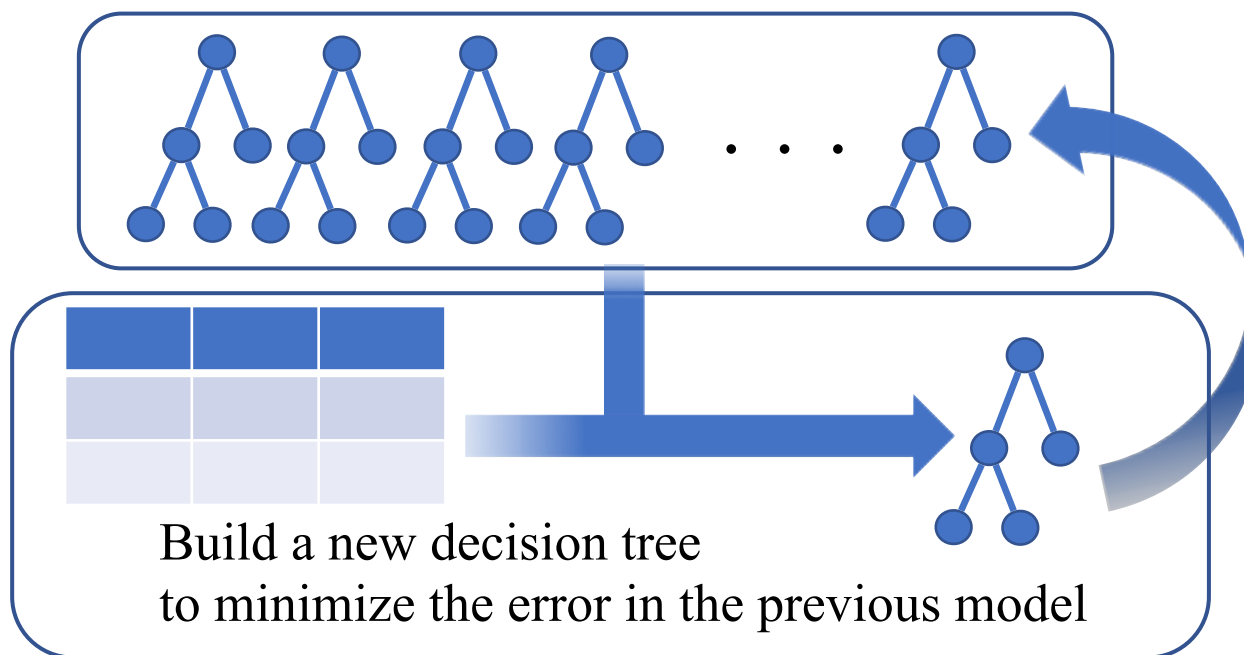
11.3 months



既存の手法は、単純なモデルであったり、計算コストが高い

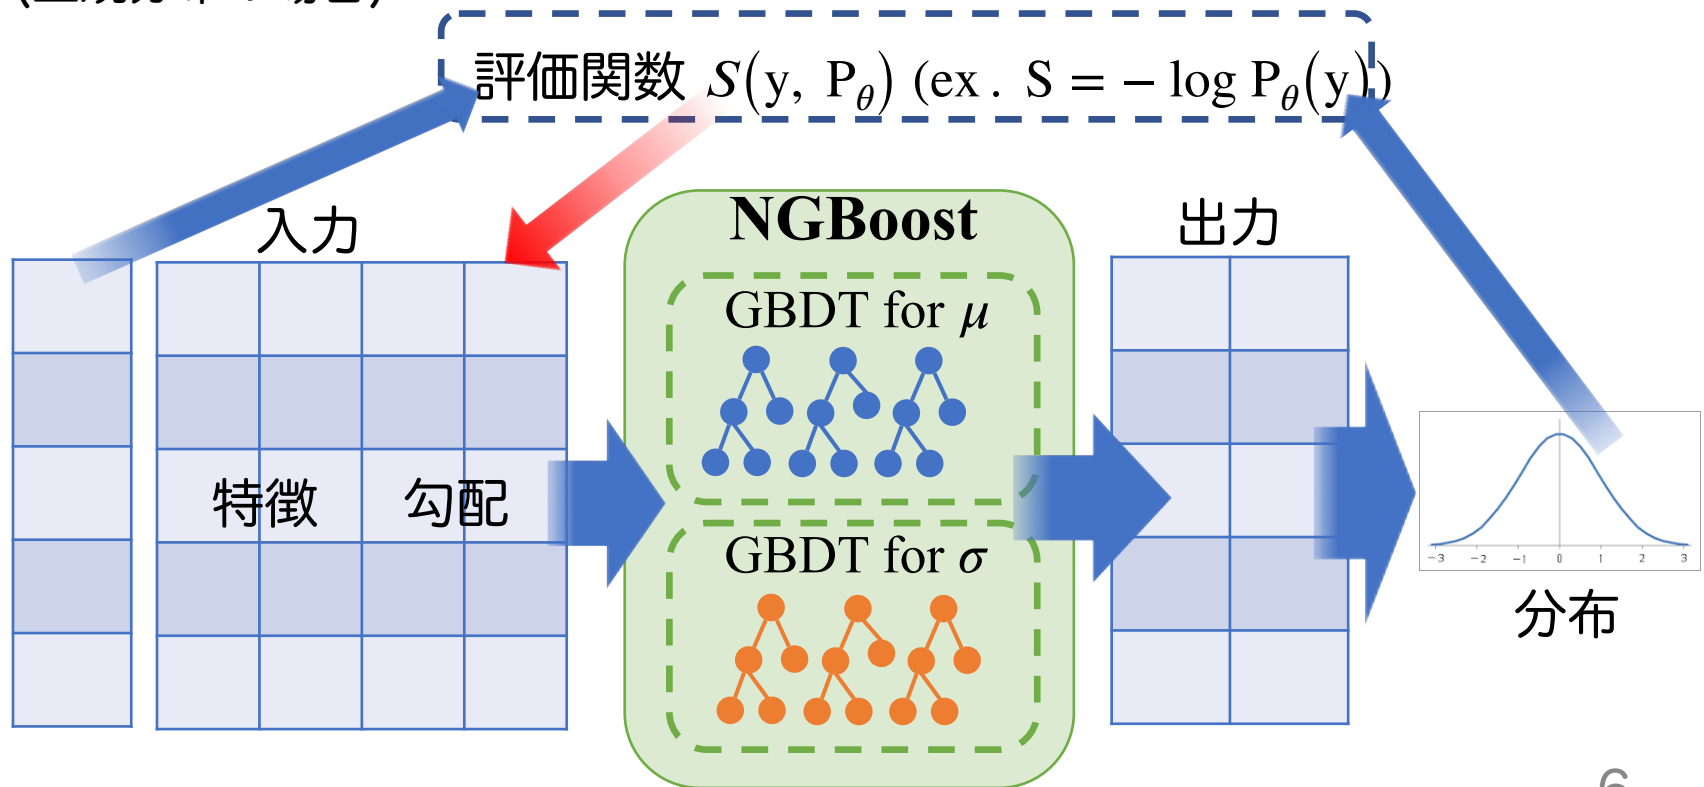
# GBDT とは

- 複数のweak learner(浅い決定木)を組み合わせたモデル
- テーブルデータに経験的に高精度
- XGBoost, Light GBM, Cat Boostなどが存在する



# NGBoostとは

- 各サンプルに対し分布のパラメータ(正規分布なら $\sigma, \mu$ )を出力
- 学習をうまく進めるためnatural gradient(自然勾配)を導入
- 各パラメータ毎にGBDTを学習するmultiparameter boostingを導入  
(正規分布の場合)



# NGBoost: 学習アルゴリズム

---

**Algorithm 1** NGBoost for probabilistic prediction

---

**Data:** Dataset  $\mathcal{D} = \{x_i, y_i\}_{i=1}^n$ .

**Input:** Boosting iterations  $M$ , Learning rate  $\eta$ , Probability distribution with parameter  $\theta$ , Proper scoring rule  $\mathcal{S}$ , Base learner  $f$ .

**Output:** Scalings and base learners  $\{\rho^{(m)}, f^{(m)}\}_{m=1}^M$ .  
 $\theta^{(0)} \leftarrow \arg \min_{\theta} \sum_{i=1}^n \mathcal{S}(\theta, y_i)$  {initialize to marginal}

**for**  $m \leftarrow 1, \dots, M$  **do**

**for**  $i \leftarrow 1, \dots, n$  **do**

$g_i^{(m)} \leftarrow \mathcal{I}_{\mathcal{S}} \left( \theta_i^{(m-1)} \right)^{-1} \nabla_{\theta} \mathcal{S} \left( \theta_i^{(m-1)}, y_i \right)$

**end**

$f^{(m)} \leftarrow \text{fit} \left( \left\{ x_i, g_i^{(m)} \right\}_{i=1}^n \right)$

$\rho^{(m)} \leftarrow \arg \min_{\rho} \sum_{i=1}^n \mathcal{S} \left( \theta_i^{(m-1)} - \rho \cdot f^{(m)}(x_i), y_i \right)$

**for**  $i \leftarrow 1, \dots, n$  **do**

$\theta_i^{(m)} \leftarrow \theta_i^{(m-1)} - \eta \left( \rho^{(m)} \cdot f^{(m)}(x_i) \right)$

**end**

**end**

---

$M$ : weak learnerの数

$n$ : サンプル数

$\eta$ : 学習率

$\theta$ : 分布のパラメータ

$f^{(m)}$ :  $m$ 個目の learner

(正規分布ならば,

$\theta = \{\mu, \sigma\}$ ,  $f^{(m)} = \{f_{\mu}^{(m)}, f_{\sigma}^{(m)}\}$ )  
自然勾配を用いて勾配を更新

木を学習,  
パラメータを更新

# NGBoost: 学習アルゴリズム

---

**Algorithm 1** NGBoost for probabilistic prediction

---

**Data:** Dataset  $\mathcal{D} = \{x_i, y_i\}_{i=1}^n$ .

**Input:** Boosting iterations  $M$ , Learning rate  $\eta$ , Probability distribution with parameter  $\theta$ , Proper scoring rule  $\mathcal{S}$ , Base learner  $f$ .

**Output:** Scalings and base learners  $\{\rho^{(m)}, f^{(m)}\}_{m=1}^M$ .

$\theta^{(0)} \leftarrow \arg \min_{\theta} \sum_{i=1}^n \mathcal{S}(\theta, y_i)$  {initialize to marginal}

**for**  $m \leftarrow 1, \dots, M$  **do**

**for**  $i \leftarrow 1, \dots, n$  **do**

$g_i^{(m)} \leftarrow \mathcal{I}_{\mathcal{S}} \left( \theta_i^{(m-1)} \right)^{-1} \nabla_{\theta} \mathcal{S} \left( \theta_i^{(m-1)}, y_i \right)$

**end**

$f^{(m)} \leftarrow \text{fit} \left( \left\{ x_i, g_i^{(m)} \right\}_{i=1}^n \right)$

$\rho^{(m)} \leftarrow \arg \min_{\rho} \sum_{i=1}^n \mathcal{S} \left( \theta_i^{(m-1)} - \rho \cdot f^{(m)}(x_i), y_i \right)$

**for**  $i \leftarrow 1, \dots, n$  **do**

$\theta_i^{(m)} \leftarrow \theta_i^{(m-1)} - \eta \left( \rho^{(m)} \cdot f^{(m)}(x_i) \right)$

**end**

**end**

---

$M$ : weak learnerの数

$n$ : サンプル数

$\eta$ : 学習率

$\theta$ : 分布のパラメータ

$f^{(m)}$ :  $m$ 個目の learner

(正規分布ならば,

$\theta = \{\mu, \sigma\}, f^{(m)} = \{f_{\mu}^{(m)}, f_{\sigma}^{(m)}\}$   
自然勾配を用いて勾配を更新

木を学習,  
パラメータを更新



# NGBoost: 自然勾配法


通常の勾配降下法では

パラメータの変動のユークリッド距離を $\epsilon$  ( $\epsilon$ は微小な定数)で固定し,

その中で最もモデルを改善する方向を示す

しかし,

- パラメータ間のユークリッド距離は分布間の差異に対応しない
- パラメータの変動をユークリッド距離で固定しても,  
パラメータ毎の感度が違えば分布の変動は固定されない



点A, B間と点C, D間のユークリッド距離は同じだが,

それらの点を示す分布(正規分布)同士の差異は大きく異なる

# NGBoost: 自然勾配法

通常の勾配 ( $g = \nabla_{\theta} S$ )

- 分布の各パラメータが分布の変動に与える影響は均一でない
- 通常の勾配ではそれらを加味できない

自然勾配 (Amari, 1998)

$$g_i^{(m)} \leftarrow \mathcal{I}_S \left( \theta_i^{(m-1)} \right)^{-1} \nabla_{\theta} S \left( \theta_i^{(m-1)}, y_i \right)$$

- 分布間の差異とパラメータ間の距離を対応させることができる
- パラメータの変動でなくモデルの変動を固定して方向を決定する
- $I_S(\theta)$ によってパラメータ毎の歪みを考慮

$I_S(\theta)$ ,  $S$ は分布間の差異として何を用いるかによって変化する

## 1. KL-divergence


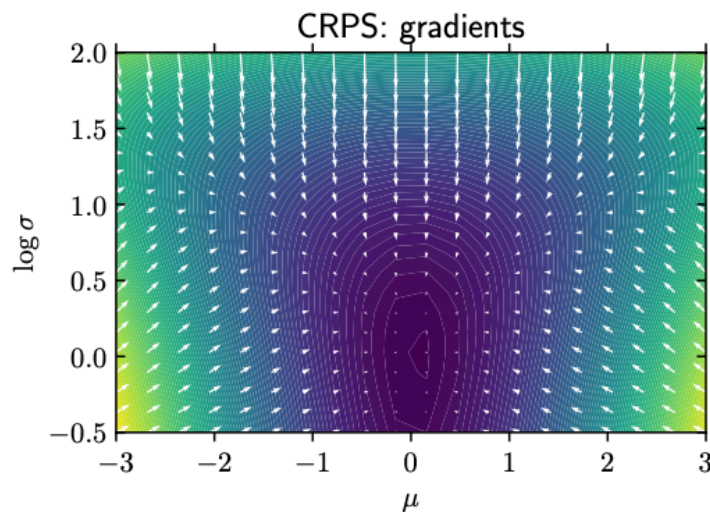
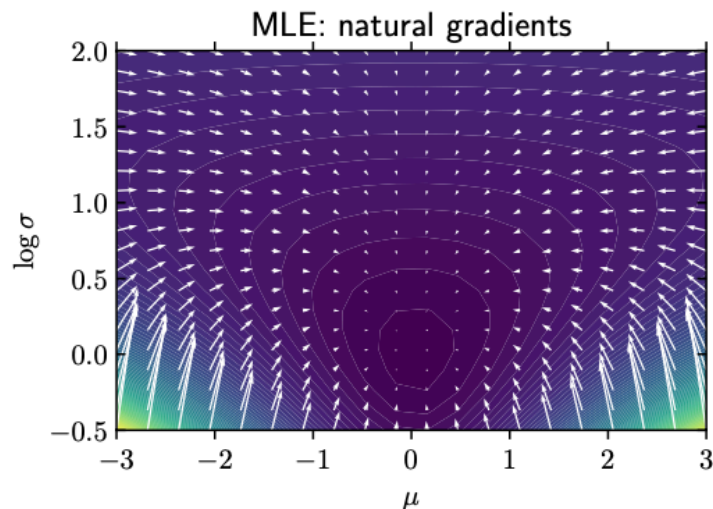

$$S = -\log(P_{\theta}(y)), I_S(\theta) = F(\theta) \text{ (フィッシャー情報量行列)}$$

## 2. L2-divergence

$$S = \text{CRPS}, I_S(\theta) = \dots \text{ (式は論文に記載されています)}$$

# NGBoost: 自然勾配法

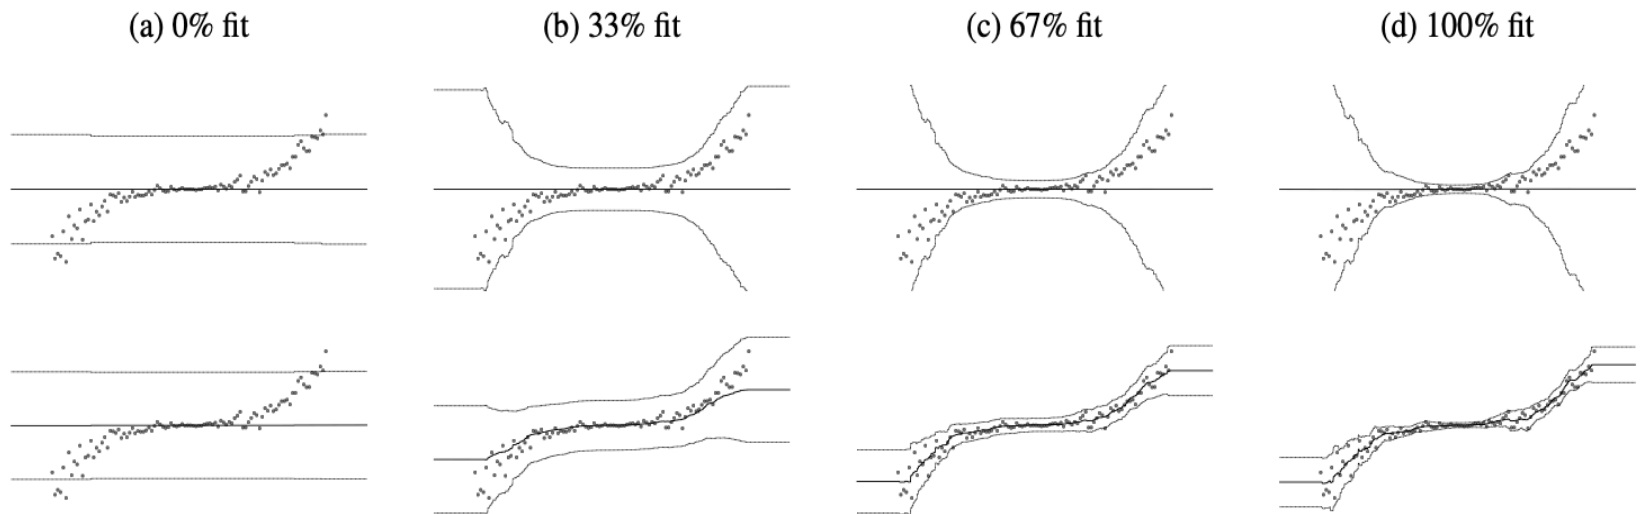
$N(0, 1)$ からの標本で勾配を計算 (左: 通常の勾配 右: 自然勾配)



# NGBoost: 自然勾配法

下図のような1次元データで学習を行なった図

(上: 通常の勾配, 下: 自然勾配)



通常勾配(上側)

平均はほとんど更新されず, 中央の分散ばかり学習

自然勾配(下側)

全体的にバランスが取れている

# NGBoost: 学習アルゴリズム

## Algorithm 1 NGBoost for probabilistic prediction

**Data:** Dataset  $\mathcal{D} = \{x_i, y_i\}_{i=1}^n$ .

**Input:** Boosting iterations  $M$ , Learning rate  $\eta$ , Probability distribution with parameter  $\theta$ , Proper scoring rule  $\mathcal{S}$ , Base learner  $f$ .

**Output:** Scalings and base learners  $\{\rho^{(m)}, f^{(m)}\}_{m=1}^M$ .

$\theta^{(0)} \leftarrow \arg \min_{\theta} \sum_{i=1}^n \mathcal{S}(\theta, y_i)$  {initialize to marginal}

**for**  $m \leftarrow 1, \dots, M$  **do**

**for**  $i \leftarrow 1, \dots, n$  **do**

$g_i^{(m)} \leftarrow \mathcal{I}_{\mathcal{S}} \left( \theta_i^{(m-1)} \right)^{-1} \nabla_{\theta} \mathcal{S} \left( \theta_i^{(m-1)}, y_i \right)$

**end**

$f^{(m)} \leftarrow \text{fit} \left( \left\{ x_i, g_i^{(m)} \right\}_{i=1}^n \right)$

$\rho^{(m)} \leftarrow \arg \min_{\rho} \sum_{i=1}^n \mathcal{S} \left( \theta_i^{(m-1)} - \rho \cdot f^{(m)}(x_i), y_i \right)$

**for**  $i \leftarrow 1, \dots, n$  **do**

$\theta_i^{(m)} \leftarrow \theta_i^{(m-1)} - \eta \left( \rho^{(m)} \cdot f^{(m)}(x_i) \right)$

**end**

**end**

$M$ : weak learnerの数

$n$ : サンプル数

$\eta$ : 学習率

$\theta$ : 分布のパラメータ

$f^{(m)}$ :  $m$ 個目の learner

(正規分布ならば,

$\theta = \{\mu, \sigma\}, f^{(m)} = \{f_{\mu}^{(m)}, f_{\sigma}^{(m)}\}$   
自然勾配を用いて勾配を更新

木を学習,  
パラメータを更新

# NGBoost: パラメータの更新

$f^{(m)}$ の学習

$g$ を応答変数として決定木を学習 (不純度を最小化するように)

出力は葉に存在するデータの応答変数の平均とする

**Scaling**  $\rho^{(m)}$ を探索

$m$ 個目の  $f$  の出力に対するスケールパラメータ

大きな

```

$$f^{(m)} \leftarrow \text{fit} \left( \left\{ x_i, g_i^{(m)} \right\}_{i=1}^n \right)$$

$$\rho^{(m)} \leftarrow \arg \min_{\rho} \sum_{i=1}^n \mathcal{S} \left( \theta_i^{(m-1)} - \rho \cdot f^{(m)}(x_i), y_i \right)$$
for  $i \leftarrow 1, \dots, n$  do  
|  $\theta_i^{(m)} \leftarrow \theta_i^{(m-1)} - \eta \left( \rho^{(m)} \cdot f^{(m)}(x_i) \right)$   
end
```

探索

# 実験結果

以下の三つの実験でNGBoostの有用性を検証した

1. 他の確率回帰モデルとの精度比較 (NLL)
2. NGBoostにおいて,  
自然勾配以外の勾配を用いた場合と比較 (NLL)
3. 他のモデル(確率回帰モデル以外)との精度比較 (RMSE)

全ての手法において, NGBoostの以下のパラメータは固定

木の深さ:3,  $\eta$ : {0.1(MSD), 0.01(others)},  $S$ :  $-\log(P_\theta(y))$ , 分布:正規分布

更新回数 $M$ のみhold-outでチューニング

# 実験結果

## 1. 他の確率回帰モデルとの精度比較 (NLL)

Dataset	$N$	NGBoost	MC dropout	Deep Ensembles	Concrete Dropout	Gaussian Process	GAMLSS	DistForest
Boston	506	<b>2.43 ± 0.15</b>	<b>2.46 ± 0.25</b>	<b>2.41 ± 0.25</b>	2.72 ± 0.01	<b>2.37 ± 0.24</b>	2.73 ± 0.56	2.67 ± 0.08
Concrete	1030	<b>3.04 ± 0.17</b>	<b>3.04 ± 0.09</b>	<b>3.06 ± 0.18</b>	3.51 ± 0.00	<b>3.03 ± 0.11</b>	3.24 ± 0.08	3.38 ± 0.05
Energy	768	<b>0.60 ± 0.45</b>	1.99 ± 0.09	1.38 ± 0.22	2.30 ± 0.00	<b>0.66 ± 0.17</b>	1.24 ± 0.86	1.53 ± 0.14
Kin8nm	8192	-0.49 ± 0.02	-0.95 ± 0.03	<b>-1.20 ± 0.02</b>	-0.65 ± 0.00	-1.11 ± 0.03	-0.26 ± 0.02	-0.40 ± 0.01
Naval	11934	-5.34 ± 0.04	-3.80 ± 0.05	-5.63 ± 0.05	<b>-5.87 ± 0.05</b>	-4.98 ± 0.02	-5.56 ± 0.07	-4.84 ± 0.01
Power	9568	2.79 ± 0.11	2.80 ± 0.05	2.79 ± 0.04	2.75 ± 0.01	2.81 ± 0.05	2.86 ± 0.04	<b>2.68 ± 0.05</b>
Protein	45730	2.81 ± 0.03	2.89 ± 0.01	2.83 ± 0.02	2.81 ± 0.00	2.89 ± 0.02	3.00 ± 0.01	<b>2.59 ± 0.04</b>
Wine	1588	<b>0.91 ± 0.06</b>	<b>0.93 ± 0.06</b>	<b>0.94 ± 0.12</b>	1.70 ± 0.00	<b>0.95 ± 0.06</b>	<b>0.97 ± 0.09</b>	1.05 ± 0.15
Yacht	308	<b>0.20 ± 0.26</b>	1.55 ± 0.12	1.18 ± 0.21	1.75 ± 0.00	<b>0.10 ± 0.26</b>	0.80 ± 0.56	2.94 ± 0.09
Year MSD	515345	3.43 ± NA	3.59 ± NA	<b>3.35 ± NA</b>	NA ± NA	NA ± NA	NA ± NA	NA ± NA

データセット10個中5つが太字(最良+標準偏差で重なる)  
→ 他の手法と比較しても, 上位の性能を誇ってる



# 実験結果

## 2. NGBoostにおいて,

自然勾配以外の勾配を用いた場合と比較 (NLL)

Dataset	N	NGBoost	2nd-Order	Multiparameter	Homoscedastic
Boston	506	<b>2.43 ± 0.15</b>	3.57 ± 0.20	3.17 ± 0.13	<b>2.79 ± 0.42</b>
Concrete	1030	<b>3.04 ± 0.17</b>	4.21 ± 0.05	3.94 ± 0.09	<b>3.22 ± 0.29</b>
Energy	768	<b>0.60 ± 0.45</b>	3.64 ± 0.06	3.24 ± 0.09	<b>0.68 ± 0.25</b>
Kin8nm	8192	-0.49 ± 0.02	0.10 ± 0.07	<b>-0.52 ± 0.03</b>	-0.37 ± 0.05
Naval	11934	<b>-5.34 ± 0.04</b>	-2.80 ± 0.01	-3.46 ± 0.00	-4.35 ± 0.07
Power	9568	2.79 ± 0.11	4.11 ± 0.03	3.79 ± 0.13	<b>2.66 ± 0.11</b>
Protein	45730	<b>2.81 ± 0.03</b>	3.23 ± 0.00	3.04 ± 0.02	2.86 ± 0.01
Wine	1588	<b>0.91 ± 0.06</b>	1.21 ± 0.09	0.93 ± 0.07	<b>1.34 ± 0.67</b>
Yacht	308	<b>0.20 ± 0.26</b>	4.11 ± 0.17	3.29 ± 0.20	2.02 ± 0.21
Year MSD	515345	<b>3.43 ± NA</b>	3.80 ± 0.00	3.60 ± NA	3.63 ± NA

データセット10個中8つが太字

→ 自然勾配を用いた場合が最も高精度

# 実験結果

## 3. 他のモデル(確率回帰モデル以外)との精度比較 (RMSE)

Dataset	$N$	NGBoost	Elastic Net	Random Forest	Gradient Boosting	GAMLSS	Distributional Forest
Boston	506	<b>2.94 ± 0.53</b>	4.08 ± 0.16	2.97 ± 0.30	<b>2.46 ± 0.32</b>	4.32 ± 1.40	3.99 ± 1.13
Concrete	1030	<b>5.06 ± 0.61</b>	12.1 ± 0.05	5.29 ± 0.16	<b>4.46 ± 0.29</b>	6.72 ± 0.59	6.61 ± 0.83
Energy	768	0.46 ± 0.06	2.75 ± 0.03	0.52 ± 0.09	<b>0.39 ± 0.02</b>	1.43 ± 0.32	1.11 ± 0.27
Kin8nm	8192	0.16 ± 0.00	0.20 ± 0.00	0.15 ± 0.00	<b>0.14 ± 0.00</b>	0.20 ± 0.01	0.16 ± 0.00
Naval	11934	<b>0.00 ± 0.00</b>	<b>0.00 ± 0.00</b>	<b>0.00 ± 0.00</b>	<b>0.00 ± 0.00</b>	<b>0.00 ± 0.00</b>	<b>0.00 ± 0.00</b>
Power	9568	3.79 ± 0.18	4.42 ± 0.00	3.26 ± 0.03	<b>3.01 ± 0.10</b>	4.25 ± 0.19	3.64 ± 0.24
Protein	45730	4.33 ± 0.03	5.20 ± 0.00	<b>3.60 ± 0.00</b>	3.95 ± 0.00	5.04 ± 0.04	3.89 ± 0.04
Wine	1588	0.63 ± 0.04	0.58 ± 0.00	<b>0.50 ± 0.01</b>	0.53 ± 0.02	0.64 ± 0.04	0.67 ± 0.05
Yacht	308	<b>0.50 ± 0.20</b>	7.65 ± 0.21	0.61 ± 0.08	<b>0.42 ± 0.09</b>	8.29 ± 2.56	4.19 ± 0.92
Year MSD	515345	8.94 ± NA	9.49 ± NA	9.05 ± NA	<b>8.73 ± NA</b>	NA ± NA	NA ± NA

データセット10個中4つが太字

→ 他手法と比較しても上位の性能

# 関連論文

---

## **Uncertainty in Gradient Boosting via Ensembles**

Ustimenko, Aleksei, Liudmila Prokhorenkova, and Andrey Malinin  
*arXiv preprint arXiv:2006.10562* (2020).

- Yandexが発表
- NGBoostより後発
- NGBoostと同じく自然勾配を利用
- CatBoost(Yandexが開発)に実装されている

詳しい内容, 差異は読んでないためわかりません.

# まとめ

---

内容

回帰問題で,

予測の不確かさ(分布)を出力可能なGBDTモデルNGBoostを提案

貢献

- ・ 勾配計算に自然勾配を導入
  - ・ パラメータ毎に異なるモデルを用いるmultiparameter boostingを導入
- メリット
- ・ チューニングが容易 (NNベースのモデルと比較して)
  - ・ 様々な分布を適用可能 (パラメータで表現できるもの)
  - ・ 他の手法に劣らない精度 (実験 1, 3)